Neural Networks

Ali Akbar Septiandri

November 24, 2017

untuk Astra Graphia IT

Daftar Isi

Ulasan Regresi Linear

Regresi linear

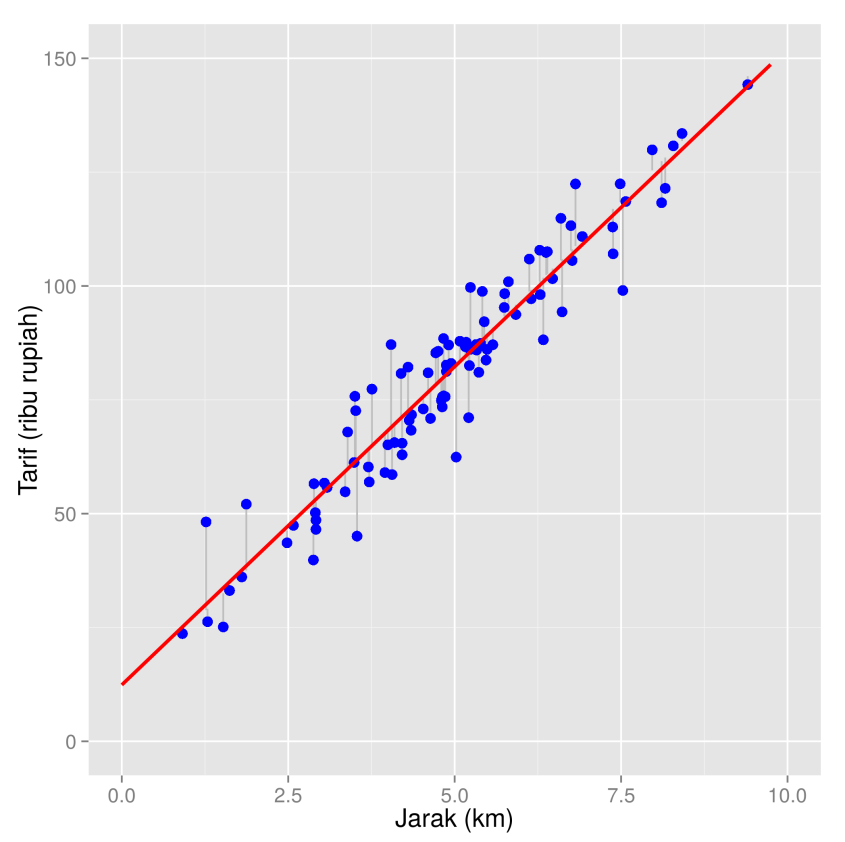

Gambar 1: Regresi linear tarif taksi dari jarak tempuh

Regresi Linear Satu Dimensi

$$y = w_0 + w_1 x_1$$

Regresi linear

Regresi Linear Multidimensi

$$y = w_0 + w_1 x_1 + ... + w_D x_D = \sum_{j=0}^{D} w_j x_j$$

Regresi Linear Multidimensi (notasi vektor)

$$y = \mathbf{w}^T \mathbf{x}$$

Optimasi analitis

- Fungsi error

$$E(\mathbf{w}) = \frac{1}{N}\sum_{i=1}^{N}(y_i - \mathbf{w}\cdot\phi(x_i))^2$$

- Solusi tertutupnya:

$$\hat{\mathbf{w}} = (\phi^T\phi)^{-1}\phi^T\mathbf{y}$$

- Bagian $(\phi^T\phi)^{-1}\phi^T$ dikenal sebagai *pseudo-inverse*

Ulasan Regresi Logistik

Regresi logistik

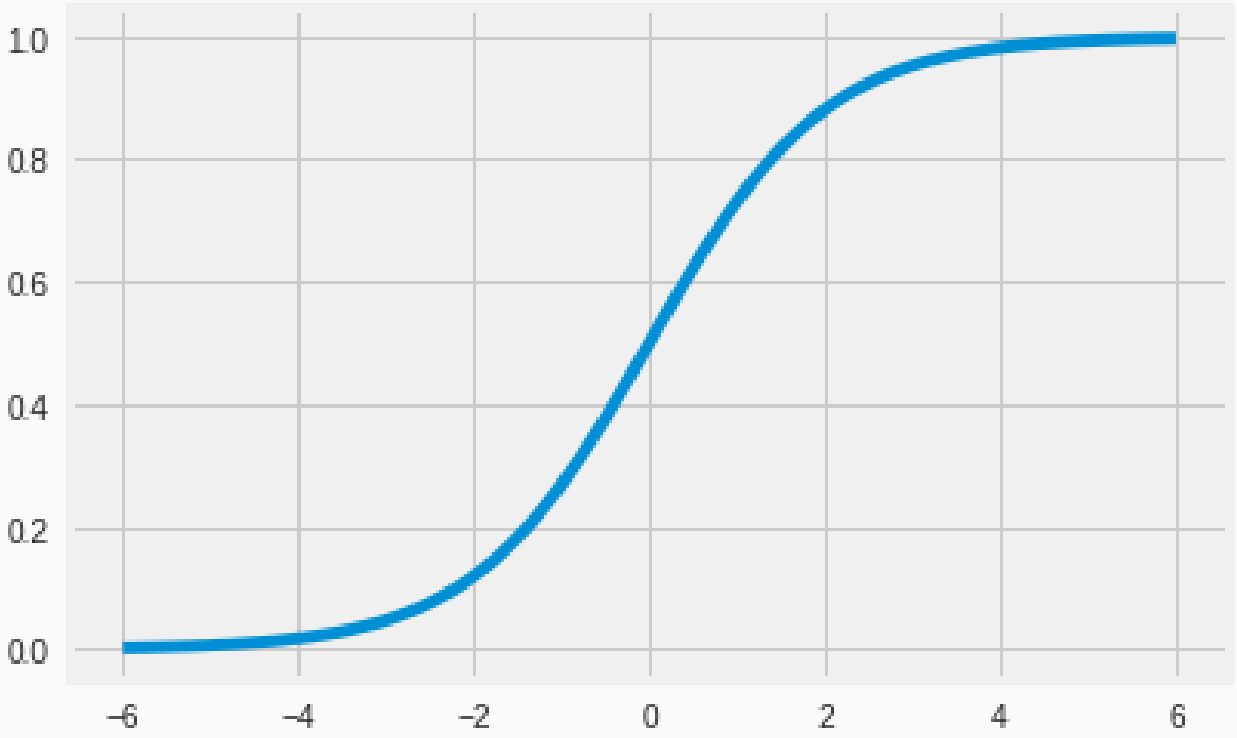

Gambar 2: Fungsi logistik $\sigma(z) = \frac{1}{1+exp(-z)}$

Probabilitas kelas dengan fungsi logistik

- Fungsi logistik (sigmoid) mengubah nilai z dari $(-\infty, \infty)$ menjadi $[0, 1]$

Regresi logistik

Probabilitas kelas dengan fungsi logistik

- Fungsi logistik (sigmoid) mengubah nilai z dari $(-\infty, \infty)$ menjadi $[0, 1]$
- Nilai $[0, 1]$ dapat diartikan sebagai probabilitas dari kelas

Regresi logistik

Probabilitas kelas dengan fungsi logistik

- Fungsi logistik (sigmoid) mengubah nilai z dari $(-\infty, \infty)$ menjadi $[0, 1]$
- Nilai $[0, 1]$ dapat diartikan sebagai probabilitas dari kelas
- Regresi linear $+$ fungsi logistik $=$ regresi logistik

Regresi Logistik

$$y = f(\mathbf{x}) = \sigma(\mathbf{w}^T \mathbf{x})$$

Optimasi numerik

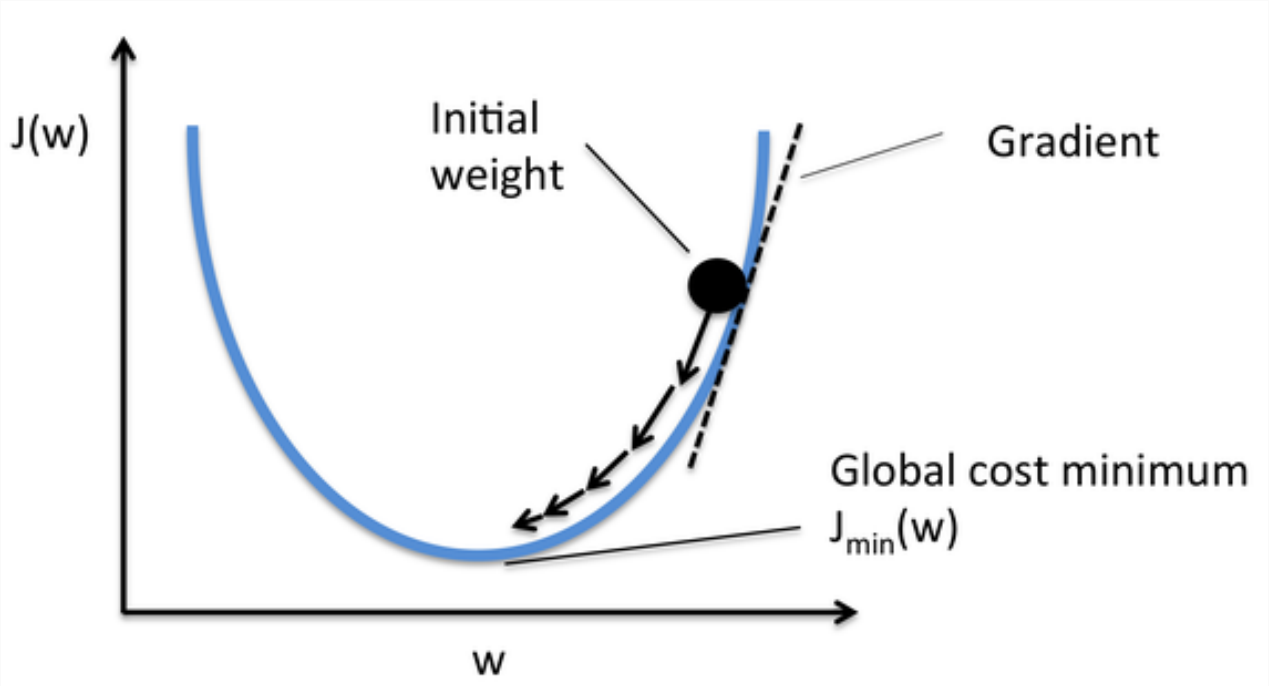

Gambar 3: Menuruni lembah fungsi error J(w) [Raschka, 2015]

Neural Networks

Jaringan saraf manusia

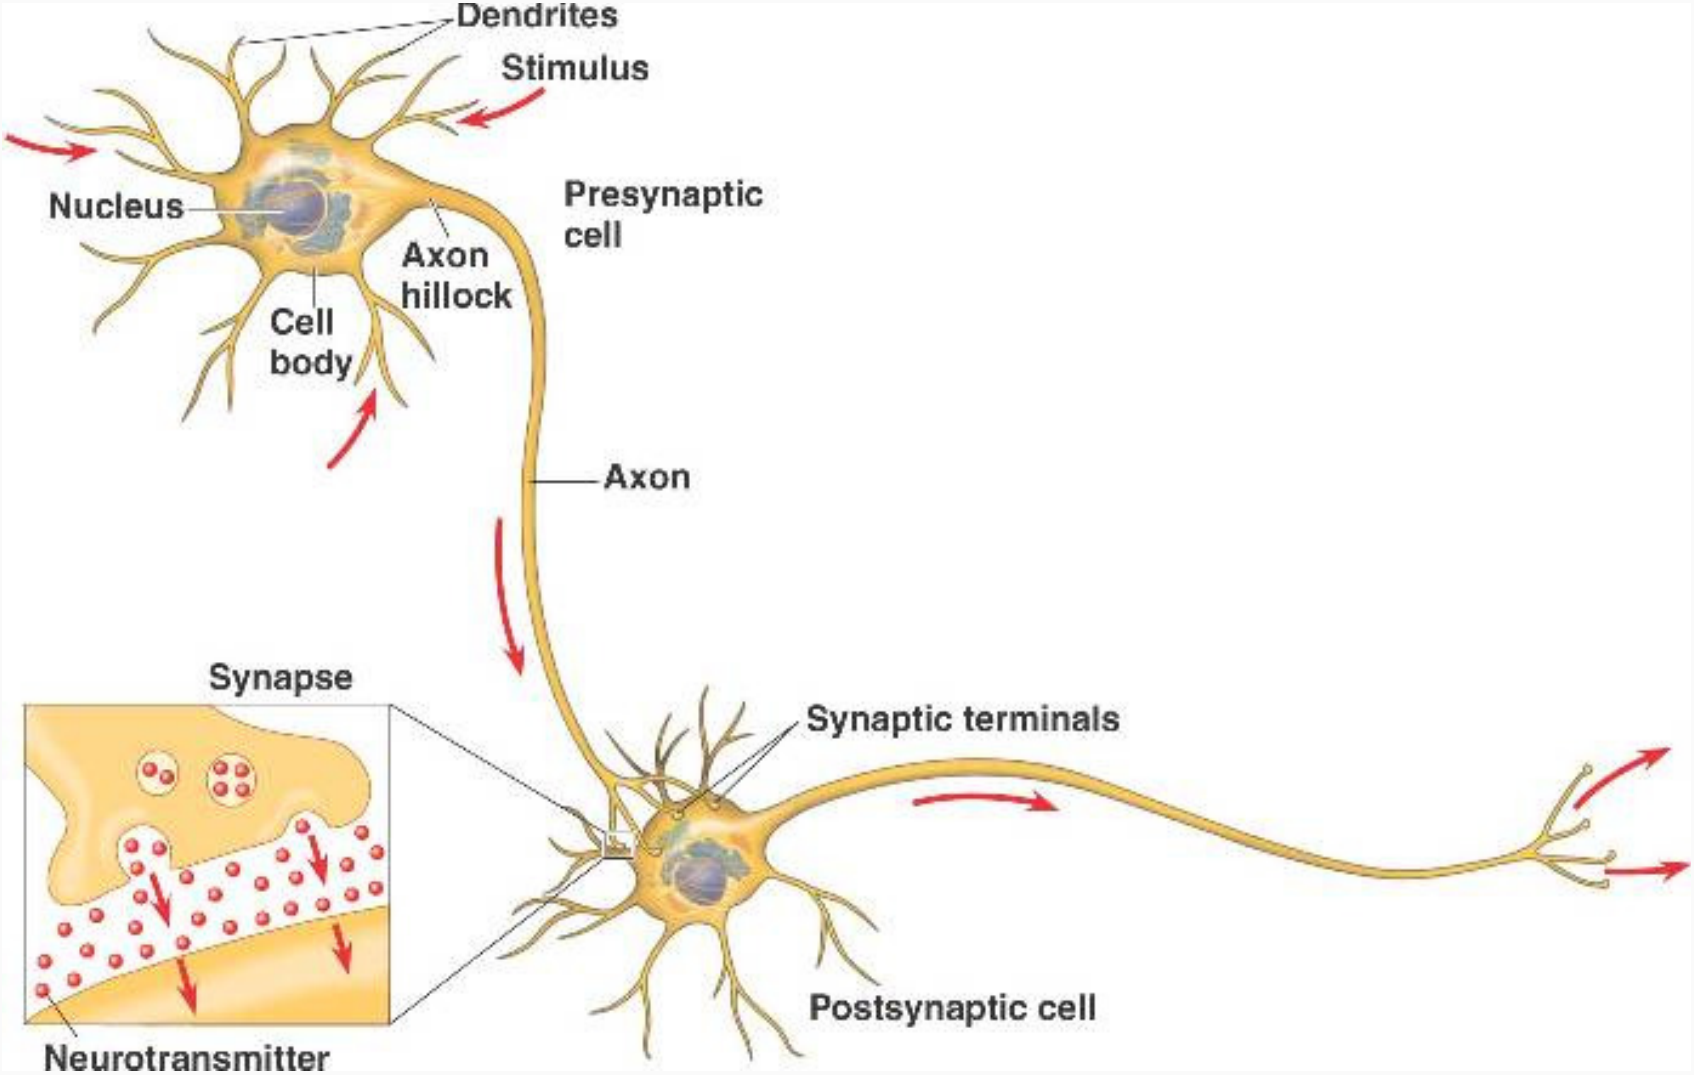

Gambar 4: Neuron pembentuk jaringan saraf [NicerWeb, 2016]

Jaringan saraf tiruan

- Bagaimana kalau kita menumpuk neuron-neuron yang ada [McCulloch dan Pitts, 1943]?

Jaringan saraf tiruan

- Bagaimana kalau kita menumpuk neuron-neuron yang ada [McCulloch dan Pitts, 1943]?
- Hasil keluaran dari suatu neuron dapat dijadikan sebagai masukan dari neuron yang lain

Jaringan saraf tiruan

- Bagaimana kalau kita menumpuk neuron-neuron yang ada [McCulloch dan Pitts, 1943]?
- Hasil keluaran dari suatu neuron dapat dijadikan sebagai masukan dari neuron yang lain
- Neuron paling akhir lah yang akan melakukan prediksi

Jaringan saraf tiruan

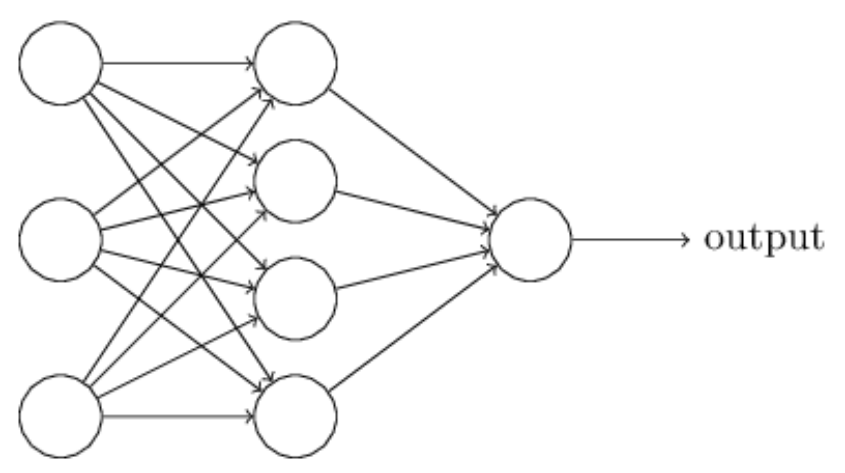

Gambar 5: Jaringan saraf tiruan [Nielsen, 2016]

Jaringan saraf tiruan

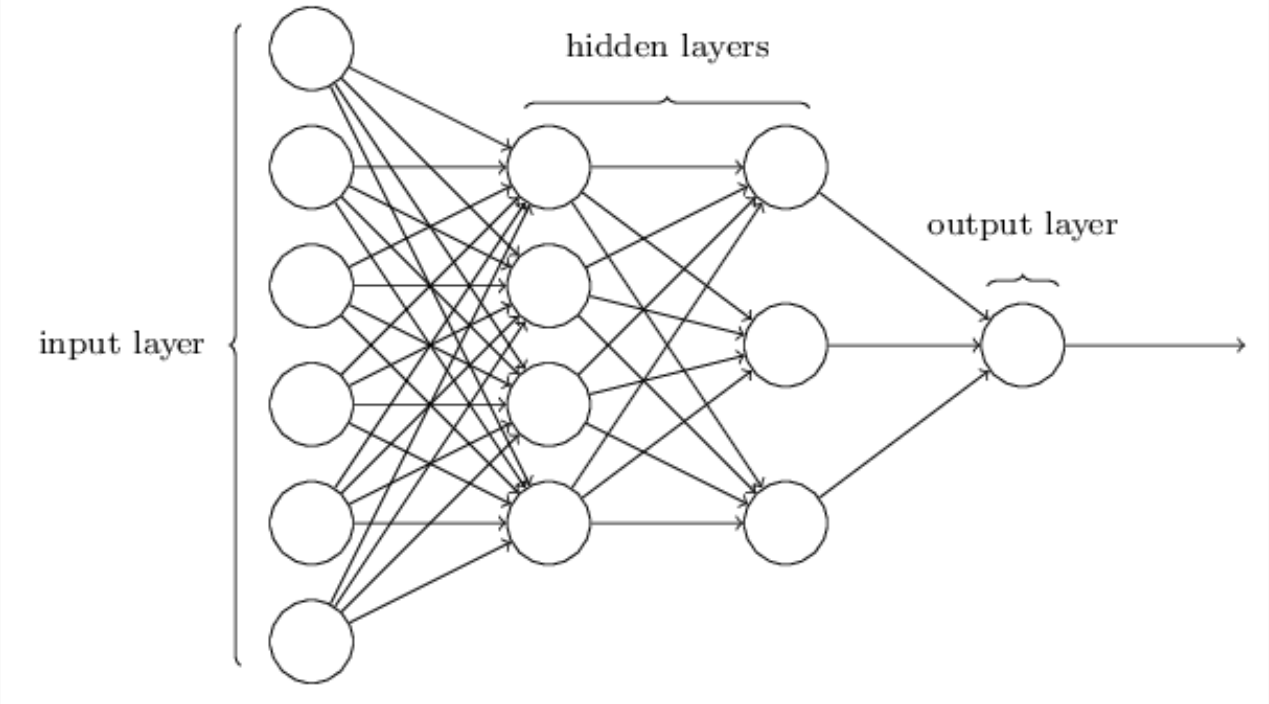

Gambar 6: Lapisan jaringan saraf tiruan [Nielsen, 2016]

Terminologi

Beberapa terminologi yang digunakan:

- *Input*, *hidden*, *output* *layers*
- Tiap *layer* terdiri dari neuron atau lebih sering disebut sebagai unit
- Terkadang satu unit dikenal juga dengan nama *perceptron*
- Fungsi sigmoid (σ) pada tiap unit merupakan salah satu contoh dari fungsi aktivasi

Hidden layers

- Jumlah *hidden layers* dapat ditentukan sendiri

Hidden layers

- Jumlah *hidden layers* dapat ditentukan sendiri
- Jaringan saraf tiruan merupakan penghampiran universal (*universal approximator*), i.e. dapat meniru berbagai fungsi kontinu dengan akurasi tertentu

Hidden layers

- Jumlah *hidden layers* dapat ditentukan sendiri
- Jaringan saraf tiruan merupakan penghampiran universal (*universal approximator*), i.e. dapat meniru berbagai fungsi kontinu dengan akurasi tertentu
- Penghampiran tersebut dapat dicapai dengan menggunakan dua *hidden layers* saja [Cybenko, 1988]!

Bagaimana cara menentukan weight-nya?

Weight matrix

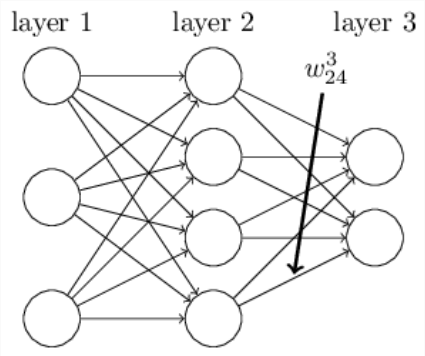

Gambar 7: Penulisan *weight* dalam skalar [Nielsen, 2016]

- Karena keluarannya menjadi masukan dari beberapa *units*, maka $y_k = \sum_{j=0}^{D} w_{kj} x_j$
- Dalam notasi matriks-vektor, keluarannya di tiap *layer* menjadi $\mathbf{y}^l = \mathbf{W}^l \mathbf{x}^{l-1}$

Regresi logistik dalam NN

Fungsi Aktivasi

Untuk tiap *layer*, $\mathbf{y}$ menggunakan fungsi aktivasi sehingga sering diganti dengan notasi $\mathbf{a}$ dan $\mathbf{z}$, maka formulanya menjadi $\mathbf{z}^l = \mathbf{W}^l \mathbf{a}^{l-1}$ dan $\mathbf{a}^l = g(\mathbf{z}^l)$, dengan $g(\cdot) = \sigma(\cdot)$

Optimasi solusi

- Masalahnya, kita belum tahu nilai **W**!

Optimasi solusi

- Masalahnya, kita belum tahu nilai **W**!
- Seperti regresi logistik, tidak ada solusi bentuk tertutup

Optimasi solusi

- Masalahnya, kita belum tahu nilai **W**!
- Seperti regresi logistik, tidak ada solusi bentuk tertutup
- Digunakanlah metode optimasi numerik, e.g. *gradient descent*

Gradient descent

- Diperlukan fungsi galat '*error function*' $E(\mathbf{w})$ yang dapat diminimalkan

Gradient descent

- Diperlukan fungsi galat '*error function*' $E(\mathbf{w})$ yang dapat diminimalkan
- Galatnya adalah perbedaan prediksi dengan nilai sebenarnya

Gradient descent

- Diperlukan fungsi galat '*error function*' $E(\mathbf{w})$ yang dapat diminimalkan
- Galatnya adalah perbedaan prediksi dengan nilai sebenarnya
- Pembelajaran $\equiv$ menuruni permukaan fungsi galat

Gradient descent

- Diperlukan fungsi galat '*error function*' $E(\mathbf{w})$ yang dapat diminimalkan
- Galatnya adalah perbedaan prediksi dengan nilai sebenarnya
- Pembelajaran $\equiv$ menuruni permukaan fungsi galat
- Akan sangat bergantung kepada **inisialisasi** nilai $\mathbf{w}$!

Cross-entropy error function

Aturan rantai turunan

$$\frac{\partial E^n}{\partial w_j} = \frac{\partial E^n}{\partial y^n}\frac{\partial y^n}{\partial a^n}\frac{\partial a^n}{\partial w_j}$$

Fungsi galat entropi-silang (cross-entropy error function)

$$E^n = -(t^n ln(y^n) + (1 - t^n) ln(1 - y^n))$$

Gradient descent

$$\frac{\partial E^n}{\partial w_j} = (y^n - t^n)x_j$$

Squared error function

Fungsi galat kuadrat (squared error function)

$$E^n = \frac{1}{2}(y^n - t^n)^2$$

Fungsi rataan galat kuadrat (mean squared error (MSE) function)

$$E(\mathbf{w}) = \frac{1}{2n}\sum_n (y^n - t^n)^2$$

Stochastic gradient descent

begin

  Inisialisasi **W** dengan nilai yang kecil

  Acak urutan data latih **X**

  while *not converged* **do**

    for $n \leftarrow 1, N$ **do**

      for $k \leftarrow 1, K$ **do**

        $y_k^n \leftarrow \sum_{j=0}^{D} w_{kj} x_j^n$

        $\delta_k^n \leftarrow y_k^n - t_k^n$

        for $j \leftarrow 1, D$ **do**

          $w_{kj} \leftarrow w_{kj} - \eta \cdot \delta_k^n \cdot x_j^n$

        end

      end

    end

  end

end

Catatan

Gradient descent

$$\delta_k^n = \frac{\partial E_k^n}{\partial a_k^n} = \frac{\partial E_k^n}{\partial y_k^n} \frac{\partial y_k^n}{\partial a_k^n}$$

Learning rate

η (terkadang juga ditulis sebagai α) disebut juga sebagai *learning rate* yang biasanya di-assign dengan nilai yang kecil (< 1)

Backpropagation

- Bagusnya, metode latihan tersebut dapat diterapkan untuk tiap lapisan sebelumnya juga!

Backpropagation

- Bagusnya, metode latihan tersebut dapat diterapkan untuk tiap lapisan sebelumnya juga!
- Dikenal dengan nama *backpropagation*

Backpropagation

- Bagusnya, metode latihan tersebut dapat diterapkan untuk tiap lapisan sebelumnya juga!
- Dikenal dengan nama *backpropagation*
- Perlu disesuaikan dengan fungsi aktivasi yang digunakan pada lapisan tersebut

Backpropagation

- Bagusnya, metode latihan tersebut dapat diterapkan untuk tiap lapisan sebelumnya juga!
- Dikenal dengan nama *backpropagation*
- Perlu disesuaikan dengan fungsi aktivasi yang digunakan pada lapisan tersebut
- Sayangnya, algoritma ini mungkin terjebak pada solusi optimum lokal

Variasi Neural Networks

Topologi

- Yang sudah kita pelajari dikenal juga sebagai *feedforward neural networks*, karena jaringannya berupa graf berarah asiklik '*directed acyclic graph*'

Topologi

- Yang sudah kita pelajari dikenal juga sebagai *feedforward neural networks*, karena jaringannya berupa graf berarah asiklik '*directed acyclic graph*'
- Jika keluaran dari suatu neuron dijadikan masukan kembali untuk neuron tersebut (siklik) $\rightarrow$ *recurrent neural networks*

Topologi

- Yang sudah kita pelajari dikenal juga sebagai *feedforward neural networks*, karena jaringannya berupa graf berarah asiklik '*directed acyclic graph*'
- Jika keluaran dari suatu neuron dijadikan masukan kembali untuk neuron tersebut (siklik) $\rightarrow$ *recurrent neural networks*
- *Recurrent neural networks* biasa digunakan untuk tugas yang berhubungan dengan urutan, e.g. *natural language processing*, *speech recognition*

Recurrent neural networks (RNN)

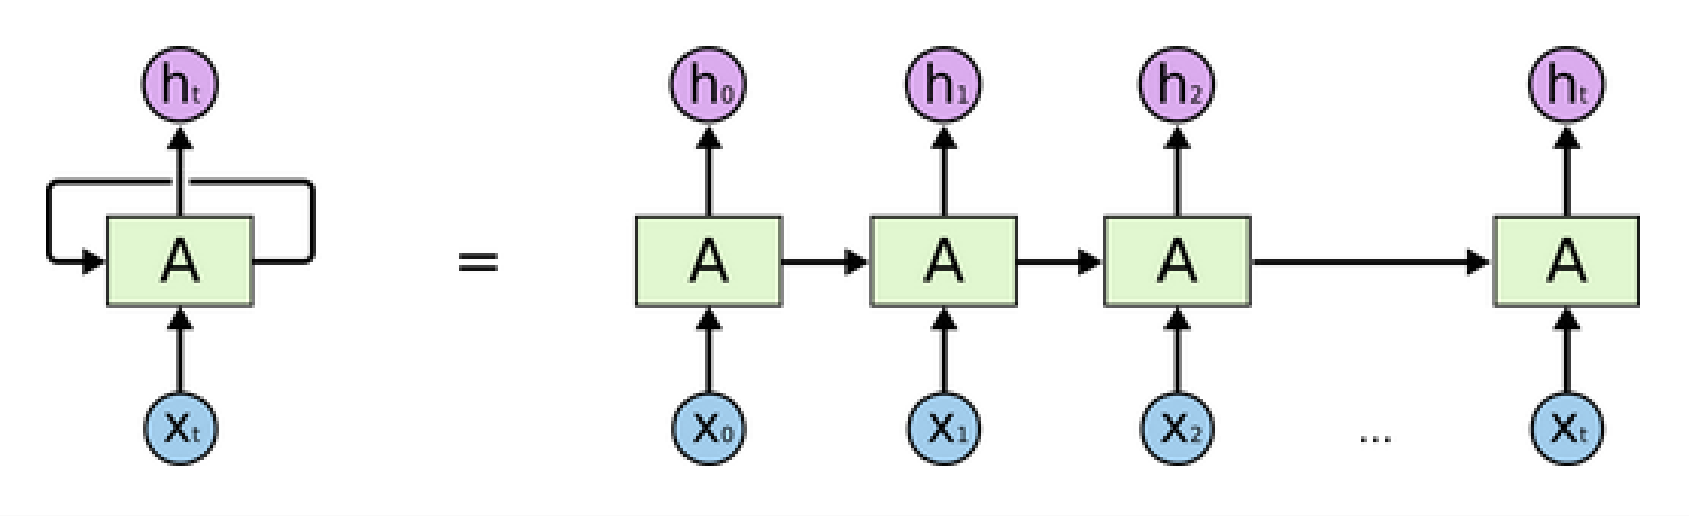

Gambar 8: Recurrent neural networks jika dilihat secara sekuensial [Olah, 2015]

Variasi fungsi aktivasi

- Fungsi sigmoid $\sigma(z)$ memiliki kelemahan, i.e. mudah sekali jenuh

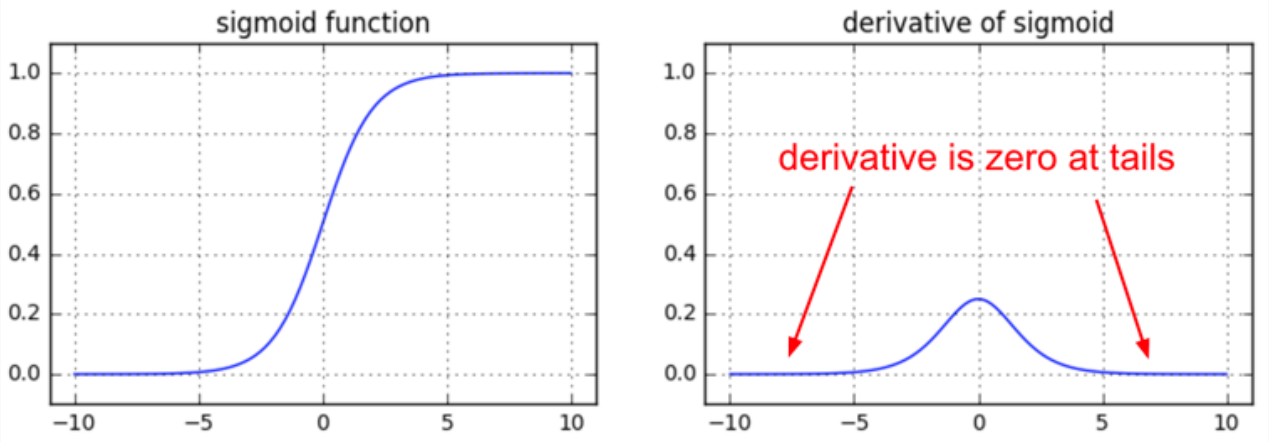

Gambar 9: Fungsi sigmoid yang jenuh karena asimtotik [Karpathy, 2016]

Variasi fungsi aktivasi

- Fungsi sigmoid $\sigma(z)$ memiliki kelemahan, i.e. mudah sekali jenuh
- Solusi: inisialisasi $\mathbf{W}$ dengan nilai yang kecil

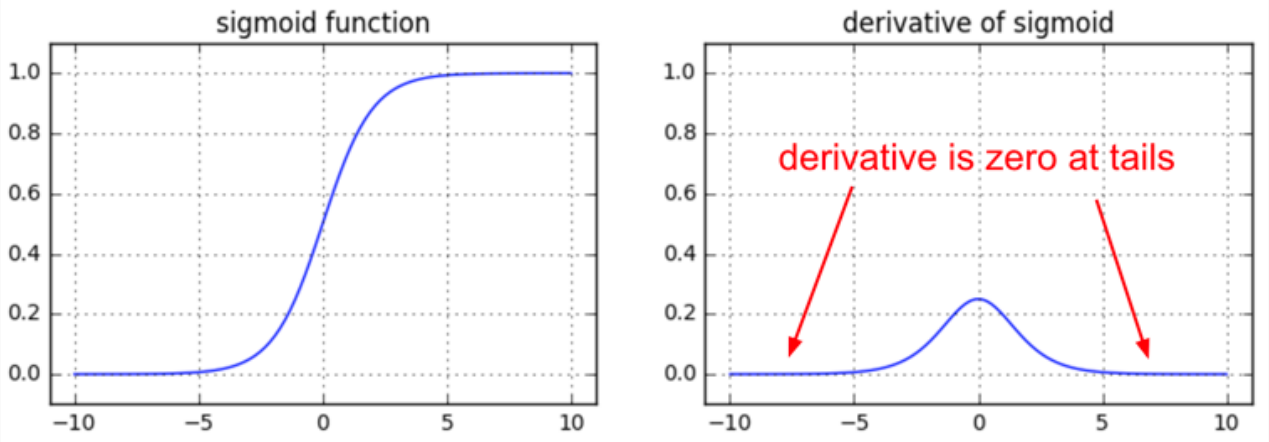

Gambar 9: Fungsi sigmoid yang jenuh karena asimtotik [Karpathy, 2016]

Variasi fungsi aktivasi

- Fungsi sigmoid $\sigma(z)$ memiliki kelemahan, i.e. mudah sekali jenuh
- Solusi: inisialisasi **W** dengan nilai yang kecil
- Diperkenalkan fungsi aktivasi lain, e.g. rectified linear unit (ReLU) $g(z) = max(0, z)$

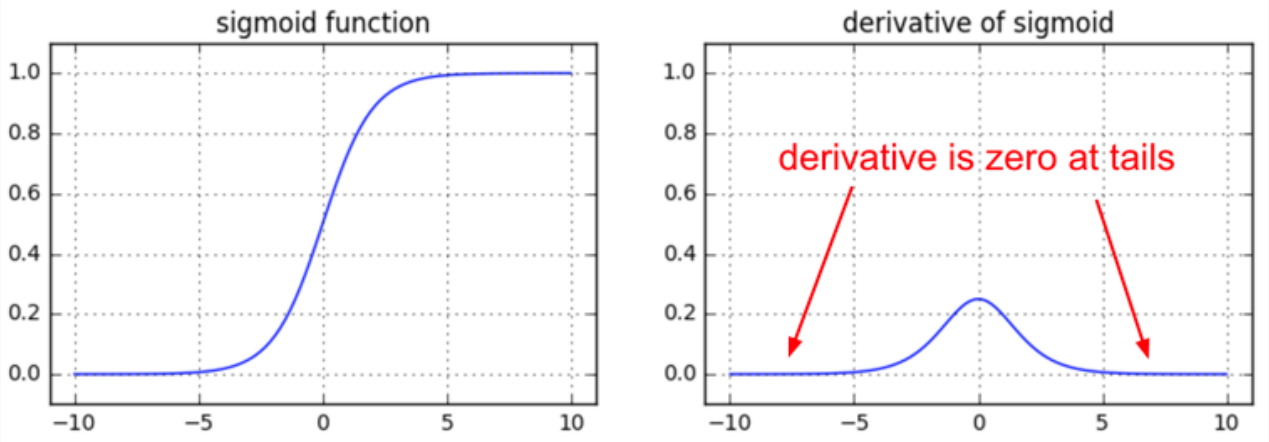

Gambar 9: Fungsi sigmoid yang jenuh karena asimtotik [Karpathy, 2016]

Variasi fungsi aktivasi

Beberapa fungsi aktivasi yang dapat digunakan

- $g(z) = \sigma(z) = \frac{1}{1+e^{-z}}$ — sigmoid
- $g(z) = tanh(z)$ — $g(z) \in [-1, 1]$ (juga cepat jenuh)
- $g(z) = z$ — linear unit
- $g(z) = \Theta(z)$ — threshold unit
- $g(z) = max(0, z)$ — rectified linear unit (ReLU)

Pengembangan neural networks

- Penggunaan *convolutional layer* dan *max pooling layer*: CNN

Pengembangan neural networks

- Penggunaan *convolutional layer* dan *max pooling layer*: CNN
- Pengembangan metode *gradient descent*, e.g. dengan *momentum* atau *performance-based*

Pengembangan neural networks

- Penggunaan *convolutional layer* dan *max pooling layer*: CNN
- Pengembangan metode *gradient descent*, e.g. dengan *momentum* atau *performance-based*
- Penggunaan regularisasi L1 dan L2

Pengembangan neural networks

- Penggunaan *convolutional layer* dan *max pooling layer*: CNN
- Pengembangan metode *gradient descent*, e.g. dengan *momentum* atau *performance-based*
- Penggunaan regularisasi L1 dan L2
- Inisialisasi dengan pralatih '*pretraining*', e.g. *autoencoder*

Aplikasi Neural Networks

Contoh implementasi NN dengan keras.io

Aplikasi NN

1. MNIST: pendeteksian digit yang ditulis tangan (LeCun dan Bengio, 1995)
2. Klasifikasi objek visual (Krizhevsky et al, 2012)
3. Speech recognition (Hinton et al, 2012)
4. Representasi vektor dari kata-kata (Mikolov et al, 2013)

Aplikasi NN

Gambar 10: Prisma yang menggunakan neural networks jenis CNN (Gatys et al, 2015)

Convolutional NNs

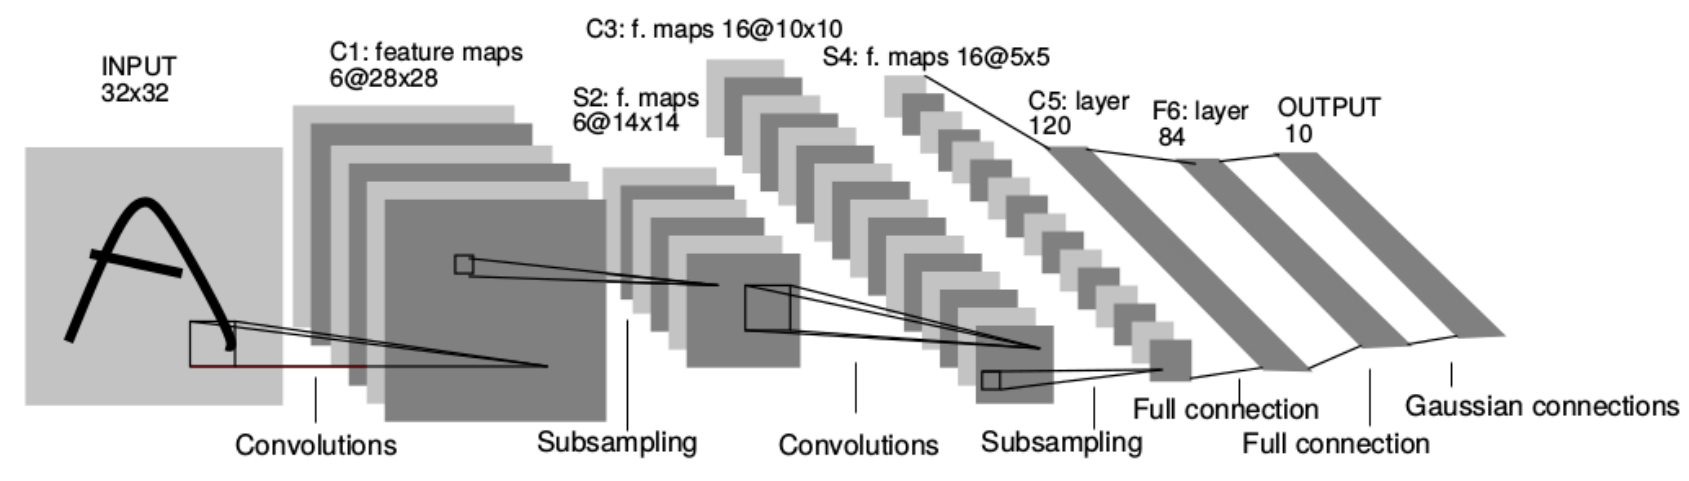

Gambar 11: Penggunaan lapisan *convolutional* dan *pooling* pada LeNet [Murphy, 2012] Fig. 16.14

Salindia ini dipersiapkan dengan sangat dipengaruhi oleh:
Chris Williams (2015) dan Steve Renals (2015)

Ikhtisar

- Merupakan penghampir universal — sangat mungkin terjadi *overfitting*
- Dapat terjebak dalam solusi optimum lokal
- Bisa jadi sangat lambat karena metode *gradient descent*
- *Gradient descent* dapat "diteruskan" ke *layer sebelumnya*, dikenal dengan nama *backpropagation*
- Punya beberapa alternatif fungsi aktivasi selain sigmoid
- Sulit diinterpretasi — sangat terbuka untuk dikembangkan

Referensi

NicerWeb (diakses tanggal 5 Desember 2016)

Neuron

http://www.nicerweb.com/bio1152/Locked/media/ch48/neuron.html

Warren S. McCulloch dan Walter Pitts (1943)

A logical calculus of the ideas immanent in nervous activity

The bulletin of mathematical biophysics 5(4), 115 – 133.

Michael Nielsen (2016)

Neural Networks and Deep Learning

http://neuralnetworksanddeeplearning.com/

Referensi

G. Cybenko (1988)

Continuous valued neural networks with two hidden layers are sufficient

Center for Supercomputing Research and Development

Sebastian Raschka (2015)

Single-Layer Neural Networks and Gradient Descent

`http://sebastianraschka.com/Articles/2015_singlelayer_neurons.html`

Christopher Olah (2015)

Understanding LSTM Networks

`http://colah.github.io/posts/2015-08-Understanding-LSTMs/`

Referensi

Andrej Karpathy (2016)

Yes you should understand backprop

https://medium.com/@karpathy/yes-you-should-understand-backprop-e2f06eab496b#.70lzt4tw2

Kevin P. Murphy (2012)

Machine Learning: a Probabilistic Perspective

MIT Press

Terima kasih